




凸集与凸函数


凸集 对任意的 $x_1, x_2 \in \mathcal{S}$ 和任意的 $\lambda \in [0, 1]$, 都有

$$\lambda x_1 + (1 - \lambda)x_2 \in \mathcal{S}$$



凸组合 设 $x_1, x_2, \dots, x_m \in \mathbb{R}^n$, $\lambda_i \geq 0, i = 1, 2, \dots, m$ 满足 $\lambda_1 + \lambda_2 + \dots + \lambda_m = 1$, 称 $\lambda_1 x_1 + \lambda_2 x_2 + \dots + \lambda_m x_m$ 为 x_1, x_2, \dots, x_m 的一个凸组合.

凸包 x_1, x_2, \dots, x_m 的所有凸组合构成的集合称为由其生成的凸包.



凸包：含有限个顶点的闭凸集, 又称多面体.

$$S = \{x \in \mathbb{R}^n \mid Ax \geq b\}$$


有界的凸多面体就是多面体

凸多面体

仿射集 设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m \in \mathbb{R}^n$, $\lambda_i \in \mathbb{R}, i = 1, 2, \dots, m$ 满足


$\lambda_1 + \lambda_2 + \dots + \lambda_m = 1$, 则称 $\lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \dots + \lambda_m \mathbf{x}_m$

为 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m$ 的仿射组合。



两个点的仿射组合是一条直线！

三个点的仿射组合是一个平面



若仿射集包含原点，则是一子空间。否则称为仿射子空间。

仿射组合 $\lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \cdots + \lambda_m \mathbf{x}_m$



$$\mathbf{x}_1 + \lambda_2(\mathbf{x}_2 - \mathbf{x}_1) + \cdots + \lambda_m(\mathbf{x}_m - \mathbf{x}_1), \quad \lambda_2, \dots, \lambda_m \in \mathbb{R}$$



$$\lambda_2(\mathbf{x}_2 - \mathbf{x}_1) + \cdots + \lambda_m(\mathbf{x}_m - \mathbf{x}_1), \quad \lambda_2, \dots, \lambda_m \in \mathbb{R}$$

线性组合

仿射集是子空间的一个平移.



对仿射集 S 中任一点 \mathbf{x} , 集合 $S - \{\mathbf{x}\}$ 为 \mathbb{R}^n 的子空间.

从外形看, 子空间和仿射集是一样的, 只是一个通过原点, 另一个不通过原点.

子空间 $S - \{\mathbf{x}\}$ 的维数称为仿射集 S 的维数.

凸函数


$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad \forall x, y \in \mathbb{R}^n, \lambda \in [0, 1]$$



凸函数的等价定义

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}), \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \lambda \in [0, 1]$$




$$f\left(\sum_{i=1}^m \lambda_i \mathbf{x}_i\right) \leq \sum_{i=1}^m \lambda_i f(\mathbf{x}_i), \quad \forall \mathbf{x}_i \in \mathbb{R}^n, \lambda_i \geq 0, i = 1, 2, \dots, m, \sum_{i=1}^m \lambda_i = 1$$

凸组合 设 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m \in \mathbb{R}^n$,

$$\lambda_1 + \lambda_2 + \dots + \lambda_m = 1, \quad \lambda_1, \lambda_2, \dots, \lambda_m \in (0, 1)$$


则称 $\lambda_1 \mathbf{x}_1 + \lambda_2 \mathbf{x}_2 + \dots + \lambda_m \mathbf{x}_m$ 为 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m$ 的一个凸组合.

凸函数的等价定义

$$f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}), \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \lambda \in [0, 1]$$



● $\text{epi}(f) = \{(\mathbf{x}, \alpha) \in \mathbb{R}^n \times \mathbb{R} \mid \alpha \geq f(\mathbf{x})\}$ 是凸集。




凸函数的等价定义

凸函数 $f(\lambda \mathbf{x} + (1 - \lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1 - \lambda)f(\mathbf{y}), \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \lambda \in [0, 1]$


连续可微

理论分析

 $f(\mathbf{y}) - f(\mathbf{x}) \geq \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}), \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

或 $(\nabla f(\mathbf{y}) - \nabla f(\mathbf{x}))^T (\mathbf{y} - \mathbf{x}) \geq 0, \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

二阶连续可微

 $\mathbf{h}^T \nabla^2 f(\mathbf{x}) \mathbf{h} \geq 0, \quad \forall \mathbf{x}, \mathbf{h} \in \mathbb{R}^n \longrightarrow f''(x) \geq 0$

Hesse阵半正定

判定准则

严格凸函数： 取严格不等号





无约束优化最优性条件

光滑优化最优性条件

数学模型

$$\min_{x \in \mathbb{R}^n} f(x)$$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ 连续可微 (光滑函数).



最优解判定：直观地，验证最优解，需将其和附近点的目标函数值逐一比较，工作量太大.

利用目标函数的连续可微性质，可建立一个简易的判断方法，这就是光滑优化问题的最优性条件.

连续可微

无约束优化问题 $\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$

定理 \mathbf{x}^* 是(局部)最优解, 则 $\nabla f(\mathbf{x}^*) = \mathbf{0}$.


证明: 反证法。取 $\mathbf{d} = -\nabla f(\mathbf{x}^*)$, $\alpha > 0$ 充分小。则

$$f(\mathbf{x}^* + \alpha \mathbf{d}) = f(\mathbf{x}^*) + \alpha \nabla f(\mathbf{x}^*)^T \mathbf{d} + o(\alpha)$$

$$= f(\mathbf{x}^*) - \alpha \|\nabla f(\mathbf{x}^*)\|^2 + o(\alpha)$$



$$< f(\mathbf{x}^*).$$

梯度零点称为优化问题的**稳定点**。它可能是最大值点，可能是最小值点，也可能二者都不是。



鞍点： 梯度为零，且从该点出发的一个方向上是最大值点，另一个方向上是最小值点。

鞍点： 比上不足比下有余！



问题： 什么条件下，稳定点是最优值点？

光滑优化最优性条件（续）

凸优化 $\min_{x \in \mathbb{R}^n} f(x)$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ 为连续可微的凸函数。

定理 凸优化问题的稳定点为其全局最优解。

即若 $\nabla f(x^*) = 0$ ，则 x^* 为优化问题的全局最小值点。

证明： 利用凸函数的性质

$$f(x) - f(x^*) \geq \langle \nabla f(x^*), x - x^* \rangle = 0.$$



无约束优化二阶最优性条件

定理 设 x^* 为优化问题 $\min_{x \in \mathbb{R}^n} f(x)$ 的最优解,
则 $\nabla f(x^*) = \mathbf{0}$, $\nabla^2 f(x^*)$ 半正定。

证明: 结论 $\nabla f(x^*) = \mathbf{0}$ 已证。

反设 $\nabla^2 f(x^*)$ 非半正定, 则存在向量 d 使得

$$d^T \nabla^2 f(x^*) d < 0.$$

取 $\alpha > 0$ 充分小。由Taylor展式


$$\begin{aligned} f(x^* + \alpha d) &= f(x^*) + \alpha \nabla f(x^*)^T d + \frac{1}{2} \alpha^2 d^T \nabla^2 f(x^*) d + o(\alpha^2) \\ &< f(x^*). \end{aligned}$$

得矛盾。



二阶必要条件的非充分性

函数 $f(x) = x^3$ 在零点满足 $\nabla f(x^*) = \mathbf{0}$, $\nabla^2 f(x^*)$ 半正定, 但零点不是其最优值点。



二阶充分条件

定理 对优化问题 $\min_{x \in \mathbb{R}^n} f(x)$, 设 $\nabla f(x^*) = 0$,
 $\nabla^2 f(x^*)$ 正定, 则 x^* 是该优化问题的严格最优解.

证明: 对任意充分靠近 x^* 的 x , 存在单位向量 d , 使得

$$x = x^* + \alpha d$$

其中 $\alpha > 0$ 充分小。 则

$$f(x) = f(x^*) + \frac{1}{2}\alpha^2 d^T \nabla^2 f(x^*) d + o(\alpha^2) > f(x^*).$$



二阶充分条件的非必要性

上述结论给出的二阶充分性条件不是必要的. 如零点是单元函数 $f(x) = x^4$ 的严格最优解, 但上述二阶充分性条件在该点并不成立.

无约束优化问题不存在充分必要的最优性条件!

最优性条件的应用

例 $\min_{x>0, y\geq 0} f(x, y) = \frac{10}{x} + \frac{(x-y)^2}{2x} + \frac{3y^2}{2x}$

分析与求解：先忽略约束。

利用 $\min_{x, y} f(x, y) = \min_x \min_y f(x, y)$

先固定 x ，关于 y 的内层优化，再求解关于 x 的外层优化

$$\min_y f(x, y) = \frac{10}{x} + \frac{(x-y)^2}{2x} + \frac{3y^2}{2x}$$

目标函数关于 y 为凸函数，利用最优性条件得最优解

$$y = \frac{1}{4}x$$

将上述最优解代入目标函数得外层优化问题

$$\min f(x) = \frac{10}{x} + \frac{3}{8}x$$

目标函数关于 x 为凸函数。再利用最优性条件得

$$x = \frac{4}{3}\sqrt{15}$$

这样 $y = \frac{1}{4}x = \frac{1}{3}\sqrt{15}$

它们满足约束条件，自然为原问题的最优解。 ■