

# 无约束优化线搜索方法

1

# 一、精确线搜索方法

优化模型  $\min_{\boldsymbol{x} \in \mathbb{R}^n} f(\boldsymbol{x})$

其中,  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  连续可微(光滑函数).

有关记号

$$\boldsymbol{g}_k = \nabla f(\boldsymbol{x}_k), \quad \boldsymbol{g}(\boldsymbol{x}) = \nabla f(\boldsymbol{x})$$

$$\boldsymbol{G}_k = \nabla^2 f(\boldsymbol{x}_k), \quad \boldsymbol{G}(\boldsymbol{x}) = \nabla^2 f(\boldsymbol{x}).$$

无法一步得到最优解

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

求解策略：逐步调优

求解过程：

$$\mathbf{x}_0 \rightarrow \mathbf{x}_1 \rightarrow \mathbf{x}_2 \rightarrow \dots$$

$$f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$$

$$\rightarrow \mathbf{x}_k \rightarrow \mathbf{x}_{k+1} \rightarrow \dots \rightarrow \mathbf{x}^*$$

最优解

$$\mathbf{x}_k \xrightarrow{?} \mathbf{x}_{k+1}$$

新迭代点

搜索方向

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

当前迭代点

步长


**下降方向** 目标函数在当前点的下降方向: 存在  $\delta > 0$  使得

$$f(\mathbf{x} + \alpha \mathbf{d}) < f(\mathbf{x}) \text{ 对任意 } \alpha \in (0, \delta]$$

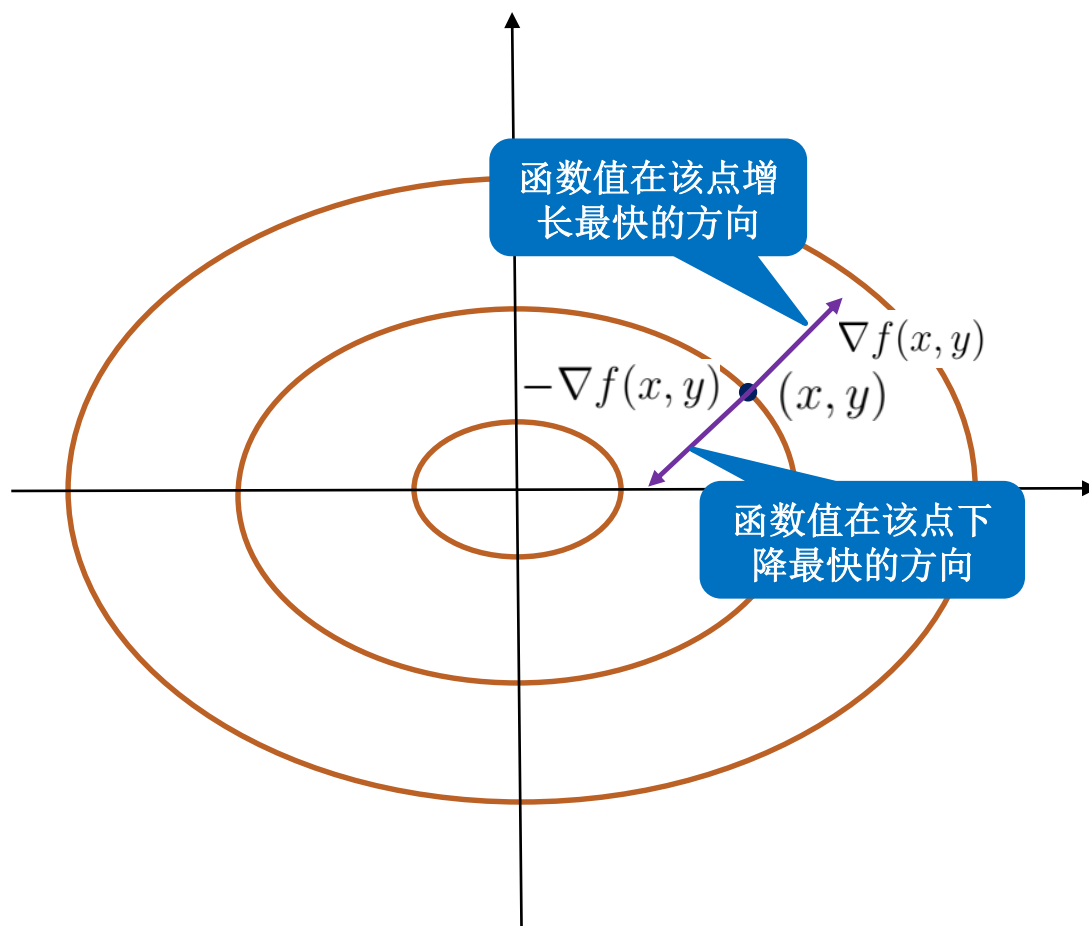
**如何判定?**

**直观分析**  $f(x, y) = x^2 + y^2 = 10$

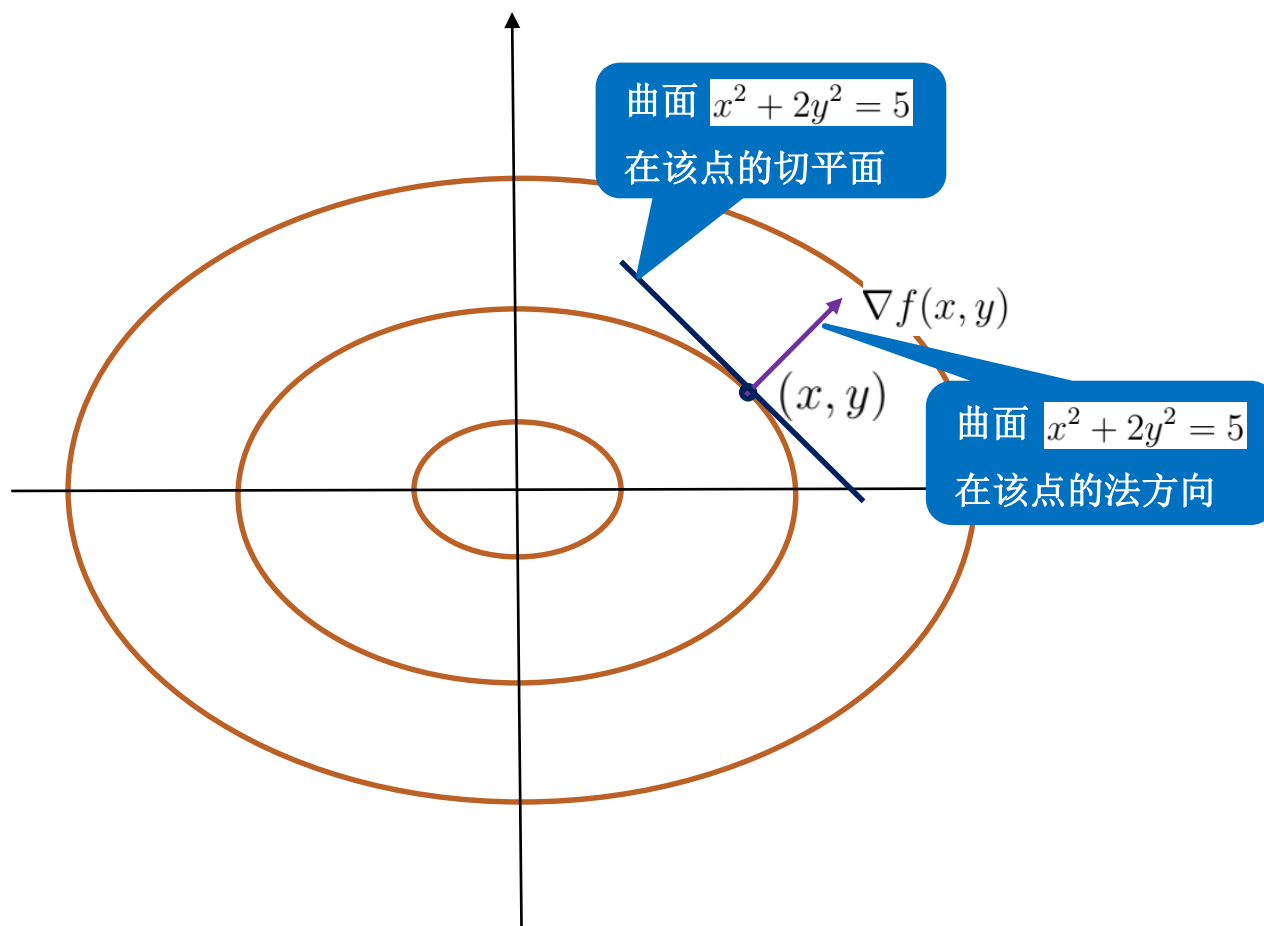
$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x \\ 2y \end{pmatrix}$$



$$f(x, y) = x^2 + 2y^2 = 10 \quad \nabla f(x, y) = \begin{pmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$$




$$f(x, y) = x^2 + 2y^2 = 5 \quad \nabla f(x, y) = \begin{pmatrix} \frac{\partial f(x, y)}{\partial x} \\ \frac{\partial f(x, y)}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$$



下降方向的判定:  $\mathbf{d}^T \nabla f(\mathbf{x}) < 0$

直观意义:  $\mathbf{d}_k$  与负梯度方向  $-\mathbf{g}_k$  的夹角呈锐角



理论分析:  $f(\mathbf{x} + \alpha \mathbf{d}) = f(\mathbf{x}) + \alpha \nabla f(\mathbf{x})^T \mathbf{d} + o(\alpha)$   
 $< f(\mathbf{x})$

$\alpha > 0$  充分小

迭代过程

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

精确线搜索

$$\alpha_k = \arg \min_{\alpha \geq 0} f(\mathbf{x}_k + \alpha \mathbf{d}_k).$$


最优步长

直观意义：沿下降方向寻求目标函数的最大下降点。

基本性质

$$f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) \leq f(\mathbf{x}_k + \alpha \mathbf{d}_k), \quad \forall \alpha > 0$$

$$f'_\alpha(\mathbf{x}_k + \alpha_k \mathbf{d}_k) = \mathbf{d}_k^T \nabla f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) = 0$$



梯度零点



## 最优步长的计算

一元函数的极值问题, 全局最优步长难求. 通常只能求得局部最优或近似最优步长。

**常用的方法：**黄金分割法、多项式插值

# 精确线搜索下降算法

步1、取初始点  $\mathbf{x}_0 \in \mathbb{R}^n$  和参数  $\varepsilon \geq 0$ . 令  $k = 0$

步2、若  $\|\mathbf{g}_k\| \leq \varepsilon$ , 算法终止; 否则, 进入下一步.

步3、计算下降方向  $\mathbf{d}_k$  满足  $\mathbf{d}_k^T \mathbf{g}_k < 0$

步4、计算步长

$$\alpha_k = \arg \min \{ f(\mathbf{x}_k + \alpha \mathbf{d}_k) \mid \alpha \geq 0 \}$$

步5、令  $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$ ,  $k = k + 1$ , 转步2

开始新迭代

## 参数选取

若算法终止规则  $\|g_k\| \leq \varepsilon$  中,  $\varepsilon = 0$ , 算法会产生无穷点列.  
实际计算时应避免。

一般取  $\varepsilon = 10^{-4}, 10^{-6}, 10^{-8}, 10^{-12}, 10^{-16}$

理论分析, 取  $\varepsilon = 0$  .

# 算法收敛性


要保证算法收敛，要对搜索方向、目标函数做些假设。

**定理** 设目标函数  $f \in C^2$  有下界，

搜索方向的一致下降性

下降方向  $d_k$  与负梯度方向  $-g_k$  的夹角满足  $\theta_k \leq \pi/2 - \theta$ ,  $0 < \theta \leq \pi/2$ .

下降性趋于零



严格锐角


若精确线搜索方法产生无穷迭代点列，

且满足  $\|\nabla^2 f(x_k + \alpha d_k)\| \leq M, \quad \forall \alpha > 0$

其中， $M > 0$  为常数，则算法收敛，即  $\lim_{k \rightarrow \infty} g_k = 0$ .

最常见的收敛性结论

下降算法产生的聚点满足  $\lim_{k \rightarrow \infty} g_k = 0$ . 该聚点即便不是最小值点, 也肯定不是最大值点, 最差是鞍点。



为求全局最优值点, 可取多个初始点进行计算, 取结点中目标函数值最小的当做全局最小值点。

若目标函数梯度一致连续，则有如下结论。

**定理** 设目标函数  $f \in C$  有下界，梯度函数在包含水平集的某邻域内一致连续，

一致下降性条件

下降方向  $d_k$  与负梯度  $-g_k$  的夹角满足  $\theta_k \leq \pi/2 - \theta, 0 < \theta \leq \pi/2$ .

若算法不有限步终止，则  $\lim_{k \rightarrow \infty} g_k = 0$ .

**水平集**  $\mathcal{L}(x_0) = \{x \in \mathbb{R}^n \mid f(x) \leq f(x_0)\}$

**一致连续** 对任意的  $\varepsilon > 0$ ，存在  $\delta > 0$ ，使对任意满足  $\|x - y\| \leq \delta$  的  $x, y \in \mathbb{R}^n$ ，均有  $|f(x) - f(y)| \leq \varepsilon$

## 较弱假设条件下的收敛性

**定理** 设目标函数  $f \in C$ . 若存在收敛子列, 使得

$$\lim_{j \rightarrow \infty} \mathbf{x}_{k_j} = \mathbf{x}^*, \quad \lim_{j \rightarrow \infty} \mathbf{d}_{k_j} = \mathbf{d}^* \quad , \quad \text{则} \quad \mathbf{g}(\mathbf{x}^*)^T \mathbf{d}^* = 0.$$

进一步, 若目标函数  $f \in C^2$ , 则  $(\mathbf{d}^*)^T \nabla^2 f(\mathbf{x}^*) \mathbf{d}^* \geq 0$ .

**注:** 未对搜索方向和目标函数梯度做要求,  
因而结论相对较弱。

## 收敛速度估计

**定理** 设搜索方向与负梯度夹角满足前面结论中的条件，即下降方向  $d_k$  与负梯度  $-g_k$  的夹角满足  $\theta_k \leq \pi/2 - \theta$  其中  $0 < \theta \leq \pi/2$ .

算法产生的迭代点列收敛到目标函数的最小值点  $x^*$ ；  
目标函数在  $x^*$  点严格凸。则迭代点列R-线性收敛。

**注：**线性收敛是一个比较慢的收敛速度。

但也要求比较强的条件。



## 最优步长小结

$$\alpha_k = \arg \min_{\alpha \geq 0} f(x_k + \alpha d_k)$$

- ✔ 目标函数沿搜索方向下降量达到最大。

理想化策略，计算量大，很难取到。

- ✔ 便于算法理论分析（如二次终止性、收敛速率等）

- ✘ 对全局最优解不起关键作用

## 二、非精确线搜索方法

最优步长的初衷是在每一迭代步使目标函数下降量达到最大. 但计算量太大, 而且不好求.

最优化问题关注全局最优值点。集中于某个方向上的线搜索似乎没有必要。

### 常见的非精确步长规则

 Armijo步长

 Wolfe步长

## 1. Armijo步长规则

设  $d_k$  为  $x_k$  点的下降方向, 即  $d_k^\top g_k < 0$

对  $\sigma \in (0, 1)$ , 只要  $\alpha > 0$  充分小

$$f(x_k + \alpha d_k) = f(x_k) + \alpha g_k^\top d_k + o(\alpha)$$

$< 0$

**步长选取:** 先取一个较大的步长, 看目标函数是否有满意的下降量。否则依次按比例压缩, 直至满足要求。又称进退试探法。

## Armijo步长规则

取常数  $\beta > 0, \sigma, \gamma \in (0, 1)$ 。步长  $\alpha_k = \beta\gamma^{m_k}$ ,

其中  $m_k$  为  $0, 1, 2, 3, \dots$  中满足下式的最小值

$$f(x_k + \beta\gamma^m d_k) \leq f_k + \sigma\beta\gamma^m g_k^\top d_k.$$

下降量

若  $\alpha_k < \beta$  , 则

$$f(x_k + \beta\gamma^{m_k} d_k) \leq f(x_k) + \sigma\beta\gamma^{m_k} g_k^\top d_k,$$

$$f(x_k + \beta\gamma^{m_k-1} d_k) > f(x_k) + \sigma\beta\gamma^{m_k-1} g_k^\top d_k.$$

## 2、Wolfe步长

常数  $0 < \sigma_1 < \sigma_2 < 1$ . 步长  $\alpha_k$  同时满足

下降性条件

$$f(\mathbf{x}_k + \alpha \mathbf{d}_k) \leq f(\mathbf{x}_k) + \sigma_1 \alpha \mathbf{g}_k^T \mathbf{d}_k,$$


$$\nabla f(\mathbf{x}_k + \alpha \mathbf{d}_k)^T \mathbf{d}_k \geq \sigma_2 \mathbf{g}_k^T \mathbf{d}_k. \quad \longleftrightarrow \quad \mathbf{g}_{k+1}^T \mathbf{d}_k \geq \sigma_2 \mathbf{g}_k^T \mathbf{d}_k.$$



$\varphi_k(\alpha) = f(\mathbf{x}_k + \alpha \mathbf{d}_k)$  的陡度比  $\alpha = 0$  点有所减缓  
从而远离当前迭代点

## 步长的存在性

$$\begin{aligned} f(\mathbf{x}_k + \alpha \mathbf{d}_k) &\leq f(\mathbf{x}_k) + \sigma_1 \alpha \mathbf{g}_k^\top \mathbf{d}_k, \\ \nabla f(\mathbf{x}_k + \alpha \mathbf{d}_k)^\top \mathbf{d}_k &\geq \sigma_2 \mathbf{g}_k^\top \mathbf{d}_k. \end{aligned}$$



## 加强版：强Wolfe步长规则

$$\nabla f(x_k + \alpha d_k)^T d_k \geq \sigma_2 g_k^T d_k$$



$$\left| \nabla f(x_k + \alpha d_k)^T d_k \right| \leq \sigma_2 \left| g_k^T d_k \right|$$

- ✓ 若  $\sigma_2=0$ ，即  $g_{k+1}^T d_k=0$ ，可视为最优步长
- ✓ Wolfe步长只考虑  $g_{k+1}^T d_k < 0$  情形，可能产生差步长；  
强Wolfe步长可避免。

# 几种非精确步长的异同

## 相同点

均要求目标函数有满意的下降量且控制步长不能太小。

## 相异点

Armijo步长最为常见；Wolfe步长包含最优步长，特别适用于共轭梯度与拟牛顿方法；Armijo步长通过进退试探技术；Wolfe步长借助多项式插值等技术。



## 非精确线搜索算法

- 步1. 取初始点  $\mathbf{x}_0 \in \mathbb{R}^n$  和参数  $\varepsilon \geq 0$  . 令  $k = 0$
- 步2. 若  $\|\mathbf{g}_k\| \leq \varepsilon$ , 算法终止; 否则, 进入下一步.
- 步3. 计算下降方向  $\mathbf{d}_k$ , 使满足  $\mathbf{d}_k^T \mathbf{g}_k < 0$
- 步4. 利用非精确步长规则计算步长  $\alpha_k$ 。
- 步5. 令  $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$ ,  $k = k + 1$ , 转步2.

# 算法收敛性

**定理** 设目标函数连续可微。Armijo步长规则下，算法产生迭代点列的任一聚点为目标函数的稳定点。

**证明：** 以  $d_k = -g_k$  为例证明。

函数值列  $\{f(\mathbf{x}_k)\}$  单调下降，迭代点列有聚点，  
函数值列有界。

下降量趋于零

$$\lim_{k \rightarrow \infty} (f(\mathbf{x}_k) - f(\mathbf{x}_{k+1})) = 0.$$

反设结论不成立，即

$$\lim_{\substack{k \in K \\ k \rightarrow \infty}} \mathbf{d}_k^T \nabla f(\mathbf{x}_k) = \lim_{\substack{k \in K \\ k \rightarrow \infty}} -\|\nabla f(\mathbf{x}_k)\|^2 < -\varepsilon_0$$

由线索搜过程

$$f(\mathbf{x}_k + \beta \gamma^{m_k} \mathbf{d}_k) \leq f(\mathbf{x}_k) + \sigma \beta \gamma^{m_k} \mathbf{g}_k^T \mathbf{d}_k,$$



$$\lim_{\substack{k \in \mathcal{K} \\ k \rightarrow \infty}} \alpha_k = 0.$$

$$f(\mathbf{x}_k + (\alpha_k/\gamma) \mathbf{d}_k) - f(\mathbf{x}_k) > \sigma(\alpha_k/\gamma) \nabla f(\mathbf{x}_k)^T \mathbf{d}_k.$$

$$f(\mathbf{x}_k + (\alpha_k/\gamma)\mathbf{d}_k) - f(\mathbf{x}_k) > \sigma(\alpha_k/\gamma)\nabla f(\mathbf{x}_k)^\top \mathbf{d}_k.$$

$$\bar{\alpha}_k \triangleq \alpha_k/\gamma \quad \text{存在 } \hat{\alpha}_k \in [0, \bar{\alpha}_k]$$

$$\nabla f(\mathbf{x}_k + \hat{\alpha}_k \mathbf{d}_k)^\top \mathbf{d}_k > \sigma \nabla f(\mathbf{x}_k)^\top \mathbf{d}_k, \quad \forall k \in \mathcal{K}, k \geq K.$$

取极限

$$\lim_{\substack{k \in K \\ k \rightarrow \infty}} \nabla f(\mathbf{x}_k)^\top \mathbf{d}_k \geq \lim_{\substack{k \in K \\ k \rightarrow \infty}} \sigma \nabla f(\mathbf{x}_k)^\top \mathbf{d}_k$$

$$(1 - \sigma) \lim_{\substack{k \in K \\ k \rightarrow \infty}} \nabla f(\mathbf{x}_k)^\top \mathbf{d}_k \geq 0 \quad \longleftrightarrow \quad \text{矛盾} \quad \lim_{\substack{k \in K \\ k \rightarrow \infty}} \mathbf{d}_k^\top \nabla f(\mathbf{x}_k) < -\varepsilon_0.$$

**定理 (Wolfe步长)** 设目标函数连续可微有下界, 梯度在水平集上Lipschitz连续. 则Wolfe步长规则下, 算法产生的点列满足

$$\sum_{k=1}^{\infty} \|\mathbf{g}_k\|^2 \cos^2(\mathbf{d}_k, -\mathbf{g}_k) < \infty.$$

**定理 (Wolfe步长)** 设目标函数连续可微有下界, 梯度在水平集上一致连续. 则Wolfe线搜索下降算法产生的点列满足

$$\lim_{k \rightarrow \infty} \frac{\mathbf{g}_k^T \mathbf{d}_k}{\|\mathbf{d}_k\|} = 0.$$

# 信赖域方法

30

# 一、信赖域方法

优化模型

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

线搜索方法

$$\mathbf{x}_k \xrightarrow{?} \mathbf{x}_{k+1} \quad f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$$

信赖域方法:

$$\mathbf{x}_k \longrightarrow \mathbf{x}_{k+1} \quad f(\mathbf{x}_{k+1}) < f(\mathbf{x}_k)$$

**算法思想:** 构造目标函数的二阶近似, 将其在当前点邻域内的最小值点作为新的迭代点.

**思想：**依据二次模型与目标函数的近似度调节信赖域半径：若新迭代点不能使目标函数有充分下降，就缩小信赖域半径；否则，扩大信赖域半径。

**关键技术：**信赖域半径的调整。



$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x})$$

构造  $f(\mathbf{x}_k + \mathbf{d})$  的二阶近似

$$m_k(\mathbf{d}) = f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d}$$

其中  $\mathbf{B}_k = \nabla^2 f(\mathbf{x}_k)$  或  $\mathbf{B}_k \approx \nabla^2 f(\mathbf{x}_k)$ .

用二次模型的最小值点  $\mathbf{d}_k$  当做  $f(\mathbf{x}_k + \mathbf{d})$  关于  $\mathbf{d}$  的最小值点。

$f(\mathbf{x}_k + \mathbf{d})$  与  $m_k(\mathbf{d})$  的近似度高低取决于  $\mathbf{d}$  的模大小

**信赖域子问题**  $\min\{m_k(\mathbf{d}) \mid \mathbf{d} \in \mathbb{R}^n, \|\mathbf{d}\| \leq \Delta_k\},$

其中,  $\Delta_k > 0$  为信赖域半径

设  $\mathbf{d}_k$  为其最优解。则目标函数与二次模型的近似度为

$$f(\mathbf{x}_k + \mathbf{d}_k) - m_k(\mathbf{d}_k) = O(\|\mathbf{d}_k\|^2)$$

若  $\mathbf{B}_k = \nabla^2 f(\mathbf{x}_k)$ , 则

$$f(\mathbf{x}_k + \mathbf{d}_k) - m_k(\mathbf{d}_k) = o(\|\mathbf{d}_k\|^2)$$

## 信赖域半径调整

调整依据： $m_k(d_k)$  与  $f(x_k + d_k)$  的近似度

模型下降量

预下降量  $\text{Pred}_k = m_k(0) - m_k(d_k),$

下降比  $r_k = \frac{\text{Ared}_k}{\text{Pred}_k}$

实下降量  $\text{Ared}_k = f(x_k) - f(x_k + d_k)$

- 若  $r_k < 0$ ,  $\text{Ared}_k < 0$ ,  $x_k + d_k$  不能作为新迭代点, 缩小信赖域半径, 重新计算  $d_k$  ;
- 若  $r_k > 0$  且靠近1, 近似度较好。令  $x_{k+1} = x_k + d_k$  。扩大信赖域半径;
- 其他情况,  $x_{k+1} = x_k + d_k$  , 不调整信赖域半径.

## 信赖域算法

最大信赖  
域半径

初始点

初始信赖  
域半径

迭代阈值

步1、取  $\hat{\Delta} > 0$ ,  $\mathbf{x}_0 \in \mathbb{R}^n$ ,  $\Delta_0 \in (0, \hat{\Delta}]$ ,  $\eta \in [0, \frac{1}{4})$ ,  $\varepsilon \geq 0$ . 令  $k = 0$

步2、若  $\|\mathbf{g}_k\| \leq \varepsilon$ , 算法终止; 否则, 进入下一步.

步3、解子问题  $\mathbf{d}_k = \arg \min \{m_k(\mathbf{d}) \mid \mathbf{d} \in \mathbb{R}^n, \|\mathbf{d}\| \leq \Delta_k\}$

计算  $r_k = \frac{\text{Ared}_k}{\text{Pred}_k}$

若  $r_k < \frac{1}{4}$ , 令  $\Delta_{k+1} = \frac{1}{4}\Delta_k$ ; 若  $r_k > \frac{3}{4}$  且  $\|\mathbf{d}_k\| = \Delta_k$ ,

令  $\Delta_{k+1} = \min\{2\Delta_k, \hat{\Delta}\}$ ; 否则, 令  $\Delta_{k+1} = \Delta_k$ .

步4、若  $r_k > \eta$ , 令  $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k$ ;

否则, 令  $\mathbf{x}_{k+1} = \mathbf{x}_k$ .  $k = k + 1$ , 转步2.

## 二、子问题求解

子问题

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \end{aligned}$$

一个启发式方法（负梯度法）

单元函数  
极值问题

将  $\mathbf{d}$  限制在负梯度方向上, 即令  $\mathbf{d} = \tau \mathbf{d}_k^s$ , 其中  $\mathbf{d}_k^s = -\mathbf{g}_k$ .

$$\begin{aligned} \min m_k(\tau \mathbf{d}_k^s) &= f(\mathbf{x}_k) - \tau \|\mathbf{g}_k\|^2 + \frac{1}{2} \tau^2 \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \\ \text{s.t. } \tau &\geq 0, \quad \|\tau \mathbf{d}_k^s\| \leq \Delta_k \end{aligned}$$

$$\tau_k = \begin{cases} \frac{\Delta_k}{\|\mathbf{g}_k\|}, & \text{若 } \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \leq 0, \\ \min \left\{ \frac{\|\mathbf{g}_k\|^2}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k}, \frac{\Delta_k}{\|\mathbf{g}_k\|} \right\}, & \text{否则.} \end{cases}$$

子问题近似解:  
Cauchy点

$$\mathbf{d}_k^c = \tau_k \mathbf{d}_k^s$$

# 三种求解算法


## 1、折线方法

信赖域半径很小时, 目标函数线性近似。最优解  $d_k^c = \tau_k d_k^s$

信赖域半径较大时, 目标函数需二阶近似, 最优解

$$d_k^B \triangleq -B_k^{-1} g_k$$

介于二者之间时, 最优解形成一条由  $d_k^c$  到  $d_k^B$  的曲线(折线)  
——dogleg方法(Powell, 1970)。



## 信赖域子问题

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \end{aligned}$$

单元函数极值问题

令最优解为

$$\mathbf{d}_k(\tau) = \begin{cases} \tau \mathbf{d}_k^u & \text{若 } \tau \in [0, 1] \\ \mathbf{d}_k^u + (\tau - 1)(\mathbf{d}_k^B - \mathbf{d}_k^u) & \text{若 } \tau \in [1, 2] \end{cases}$$

参数值待定


其中

$$\mathbf{d}_k^u = -\frac{\|\mathbf{g}_k\|^2}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k} \mathbf{g}_k \quad \mathbf{d}_k^B \triangleq -\mathbf{B}_k^{-1} \mathbf{g}_k$$

## 2、二维子空间方法

将信赖域子问题

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \end{aligned}$$



可行域限制到子空间  $\text{span}[\mathbf{g}_k, \mathbf{B}_k^{-1} \mathbf{g}_k]$ .

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \\ \mathbf{d} &\in \text{span}[\mathbf{g}_k, \mathbf{B}_k^{-1} \mathbf{g}_k] \end{aligned}$$



### 3、精确解方法

利用最优性理论对信赖域子问题

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \end{aligned}$$

的最优解进行刻画，得最优解满足

$$\begin{cases} \|\mathbf{d}_k\| \leq \Delta_k, \\ (\mathbf{B}_k + \mu_k \mathbf{I}) \mathbf{d}_k = -\mathbf{g}_k, \\ \mu_k (\Delta_k - \|\mathbf{d}_k\|) = 0, \\ (\mathbf{B}_k + \mu_k \mathbf{I}) \text{ 半正定.} \end{cases}$$

**注：**只是对最优解进行了刻画，并未给出最优解。

## 子问题算法小结

- 负梯度法、折线方法、二维子空间方法给出的都是近似解，精确解方法难于计算；
- 折线方法、二维子空间方法给出的解都优于Cauchy点。

# 三、方法收敛性

引理 (子问题下降量估计) 信赖域子问题

$$\begin{aligned} \min m_k(\mathbf{d}) &= f(\mathbf{x}_k) + \mathbf{g}_k^T \mathbf{d} + \frac{1}{2} \mathbf{d}^T \mathbf{B}_k \mathbf{d} \\ \text{s.t. } \|\mathbf{d}\| &\leq \Delta_k \end{aligned}$$

在负梯度方向上的最优解(Cauchy点)  $\mathbf{d}_k^c = \tau_k \mathbf{d}_k^s$

$$\tau_k = \begin{cases} \frac{\Delta_k}{\|\mathbf{g}_k\|}, & \text{若 } \mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k \leq 0, \\ \min \left\{ \frac{\|\mathbf{g}_k\|^2}{\mathbf{g}_k^T \mathbf{B}_k \mathbf{g}_k}, \frac{\Delta_k}{\|\mathbf{g}_k\|} \right\}, & \text{否则.} \end{cases}$$

$$\text{满足 } m_k(\mathbf{d}_k^c) - m_k(\mathbf{0}) \leq -\frac{1}{2} \|\mathbf{g}_k\| \min\{\Delta_k, \frac{\|\mathbf{g}_k\|}{\|\mathbf{B}_k\|}\}.$$

**注：**折线方法、二维子空间方法给出的最优解均满足该性质！

## 算法收敛性

**定理** 设目标函数在水平集  $\mathcal{L}(x_0)$  上连续可微有下界  
信赖域算法满足  $\eta = 0$ , 存在  $\beta > 0$ , 使对任意的  $k$ ,  
 $\|B_k\| \leq \beta$ , 信赖域子问题的解  $d_k$  满足

$$m_k(d_k) - m_k(0) \leq -\frac{1}{2} \|g_k\| \min\{\Delta_k, \frac{\|g_k\|}{\|B_k\|}\}$$

则算法产生的点列满足

$$\liminf_{k \rightarrow \infty} \|g_k\| = 0.$$

**定理** 设目标函数梯度Lipschitz连续, 在水平集上有下界; 信赖域算法满足  $\eta \in (0, \frac{1}{4})$ , 存在  $\beta > 0$  使对任意的  $k$ ,  $\|B_k\| \leq \beta$ . 信赖域子问题的解  $d_k$  满足

$$m_k(d_k) - m_k(\mathbf{0}) \leq -\frac{1}{2} \|g_k\| \min\{\Delta_k, \frac{\|g_k\|}{\|B_k\|}\}$$

则算法产生的点列满足

$$\lim_{k \rightarrow \infty} g_k = \mathbf{0}.$$