

最小二乘问题

教学提纲



最小二乘问题



线性最小二乘



非线性最小二乘


一、最小二乘问题

问题引入

例：考察人的体重和肺活量之间的关系

编号	1	2	3	4	5	6	7	8	9	10	11	12
体重 (kg)	42	42	46	46	46	50	50	50	52	52	58	58
肺活量 (L)	2.55	2.2	2.75	2.4	2.8	2.81	3.41	3.1	3.46	2.85	3.5	3


肺活量 L



$$\min_{a,b} \sum_{i=1}^{12} (y_i - l_i)^2 = \sum_{i=1}^{12} ((ax_i + b) - l_i)^2$$

肺活量 L

线性最小二乘



最小二乘问题起源：

19世纪初由德国数学家Gauss在预测行星运行轨道时提出。

模型输出变量

模型参数

模型输入变量

基本思想：通过函数模型 $y = \phi(x, t)$, 对观测数据进行拟合，探讨输入数据和输出数据之间的数学关系。

输入数据	观测数据	模型数据
t_1	y_1	$\phi(x, t_1)$
t_2	y_2	$\phi(x, t_2)$
\vdots	\vdots	\vdots
t_m	y_m	$\phi(x, t_m)$

最小二乘问题数学模型

$$\min_{x \in R^n} \sum_{i=1}^m (y_i - \phi(x, t_i))^2$$

模型特点：

- $m \gg n$
- 目标函数为平方和形式，函数值非负。
- 拟合函数选取恰当时，目标函数的最优值靠近零。

只讨论拟合函数中参数的取值，不关心拟合函数的选取。

最小二乘 $\min_{x \in R^n} \sum_{i=1}^m (y_i - \phi(x, t_i))^2$

$r_i(x) = y_i - \phi(x, t_i), i = 1, 2, \dots, m,$

$r(x) = (r_1(x); r_2(x); \dots; r_m(x))$

$\min_{x \in R^n} r(x)^T r(x)$

$\min_{x \in R^n} \frac{1}{2} r(x)^T r(x)$

$r(x)$ 线性

$r(x)$ 非线性

线性最小二乘

非线性最小二乘

二、线性最小二乘

数学模型

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} r(x)^T r(x)$$



$$r(x) = Ax - b$$

$$A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$$

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|^2$$

定理 线性最小二乘问题存在全局最优解。它有唯一最优解的充分必要条件是矩阵 A 列满秩。

证明：

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|^2$$

 凸优化最优化条件

$$A^T A x = A^T b$$

由线性代数的知识

$$A^T b \in \mathcal{R}(A^T) = \mathcal{R}(A^T A)$$

线性方程组 $A^T A x = A^T b$ 有解，且在矩阵 A 列满秩时，

$A^T A$ 非奇异。



二、非线性最小二乘

数学模型

$$\min_x \frac{1}{2} \|r(x)\|^2$$

无约束优化



最速下降法？**太慢！**

牛顿算法？**太累！不收敛！**

共轭梯度法？**太繁琐！**

问题： 目标函数为平方和形式，且最优值靠近零。

有无针对该问题的有效算法？

模型分析

$$\min_x f(x) := \frac{1}{2} \|r(x)\|^2$$

➤ 梯度：

$$\nabla f(\mathbf{x}) = \mathbf{g}(\mathbf{x}) = \nabla \left(\frac{1}{2} \mathbf{r}(\mathbf{x})^T \mathbf{r}(\mathbf{x}) \right) = \mathbf{J}(\mathbf{x})^T \mathbf{r}(\mathbf{x}) = \sum_{i=1}^m r_i(\mathbf{x}) \nabla r_i(\mathbf{x})$$

$$\mathbf{J}(\mathbf{x}) = D_{\mathbf{x}} \mathbf{r}(\mathbf{x}) = \begin{pmatrix} \frac{\partial r_1(\mathbf{x})}{\partial x_1} & \frac{\partial r_1(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial r_1(\mathbf{x})}{\partial x_n} \\ \frac{\partial r_2(\mathbf{x})}{\partial x_1} & \frac{\partial r_2(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial r_2(\mathbf{x})}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial r_m(\mathbf{x})}{\partial x_1} & \frac{\partial r_m(\mathbf{x})}{\partial x_2} & \dots & \frac{\partial r_m(\mathbf{x})}{\partial x_n} \end{pmatrix}$$

➤ Hesse阵

$$\begin{aligned}\nabla^2 f(\boldsymbol{x}) = \mathbf{G}(\boldsymbol{x}) &= \sum_{i=1}^m \nabla r_i(\boldsymbol{x}) \nabla^T r_i(\boldsymbol{x}) + \sum_{i=1}^m r_i(\boldsymbol{x}) \nabla^2 r_i(\boldsymbol{x}) \\ &= \mathbf{J}(\boldsymbol{x})^T \mathbf{J}(\boldsymbol{x}) + \sum_{i=1}^m r_i(\boldsymbol{x}) \nabla^2 r_i(\boldsymbol{x}) \\ &\triangleq \mathbf{J}(\boldsymbol{x})^T \mathbf{J}(\boldsymbol{x}) + \mathbf{S}(\boldsymbol{x}).\end{aligned}$$

$$\mathbf{S}(\boldsymbol{x}) = \sum_{i=1}^m r_i(\boldsymbol{x}) \nabla^2 r_i(\boldsymbol{x})$$

➤ 牛顿算法


$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - (\mathbf{J}_k^T \mathbf{J}_k + \mathbf{S}_k)^{-1} \mathbf{J}_k^T \mathbf{r}(\boldsymbol{x}_k)$$

二阶导数项 $\mathbf{S}(\boldsymbol{x}) = \sum_{i=1}^m r_i(\boldsymbol{x}) \nabla^2 r_i(\boldsymbol{x})$ 的计算量大，且未必收敛！

Newton方法

$$\mathbf{x}_{k+1} = \mathbf{x}_k - (\mathbf{J}_k^T \mathbf{J}_k + \mathbf{S}_k)^{-1} \mathbf{J}_k^T \mathbf{r}(\mathbf{x}_k)$$


残量函数 $\mathbf{r}(\mathbf{x})$ 最优值很小时,
 $\mathbf{S}(\mathbf{x}) = \sum_{i=1}^m r_i(\mathbf{x}) \nabla^2 r_i(\mathbf{x})$ 很小



Gauss–Newton方向

$$\mathbf{d}_k^{\text{GN}} = -(\mathbf{J}_k^T \mathbf{J}_k)^{-1} \mathbf{J}_k^T \mathbf{r}(\mathbf{x}_k)$$

若 \mathbf{J}_k 列满秩,
 \mathbf{d}_k^{GN} 为下降方向



Gauss–Newton方法

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k^{\text{GN}}$$

Gauss–Newton算法收敛性

定理 设目标函数水平集有界, 残量函数 $r(x)$ 及其**Jacob** $J(x)$ 在水平集上**Lipschitz**连续, 且在水平集上满足正则性条件, 即存在 $\gamma > 0$, 使对任意 $x \in \mathcal{L}(x_0)$, 都有

$$\|J(x)y\| \geq \gamma \|y\|, \quad \forall y \in \mathbb{R}^n.$$

则**Wolfe**步长规则下的**G-N**算法产生点列的任一聚点为最小二乘问题的稳定点.

运行及收敛性条件: 残量函数的**Jacob**阵 $J(x)$ 列满秩

Gauss–Newton算法的改进

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \alpha_k \boldsymbol{d}_k^{\text{GN}}$$

$$\boldsymbol{d}^{\text{GN}} = -(\boldsymbol{J}(\boldsymbol{x})^T \boldsymbol{J}(\boldsymbol{x}))^{-1} \boldsymbol{J}(\boldsymbol{x})^T \boldsymbol{r}(\boldsymbol{x})$$

$$= \arg \min_{\boldsymbol{d} \in \mathbb{R}^n} \frac{1}{2} \| \boldsymbol{r}(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x}) \boldsymbol{d} \|^2$$

运行条件：Jacob阵 $\boldsymbol{J}(\boldsymbol{x})$ 满足正则性条件（列满秩）

添加正则项

$\boldsymbol{r}(\boldsymbol{x} + \boldsymbol{d})$ 线性近似

$\mu > 0$

$$\min_{\boldsymbol{d} \in \mathbb{R}^n} \| \boldsymbol{r}(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x}) \boldsymbol{d} \|^2 + \mu \|\boldsymbol{d}\|^2$$

最优化条件

线性近似度提升

Levenberg–Marquardt方法

$$\boldsymbol{d}^{\text{LM}} = -(\boldsymbol{J}(\boldsymbol{x})^T \boldsymbol{J}(\boldsymbol{x}) + \mu \boldsymbol{I})^{-1} \boldsymbol{J}(\boldsymbol{x})^T \boldsymbol{r}(\boldsymbol{x}).$$

Levenberg–Marquardt方法

$$\mathbf{d}^{\text{LM}} = -(\mathbf{J}(x)^T \mathbf{J}(x) + \mu I)^{-1} \mathbf{J}(x)^T \mathbf{r}(x).$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k^{\text{LM}}$$

参数 μ 影响 \mathbf{d}^{LM} 的长度和方向

性质1 $\|\mathbf{d}(\mu)\|$ 关于 $\mu > 0$ 单调不增，且 $\mu \rightarrow \infty$ 时， $\|\mathbf{d}(\mu)\| \rightarrow 0$


性质2 $\mathbf{d}(\mu)$ 与 $-\mathbf{g}(x)$ 的夹角关于 $\mu > 0$ 单调不增。

即参数 μ 越大， $\mathbf{d}(\mu)$ 越靠近目标函数的负梯度方向，其下降性越强。

证明要点：利用导数的符号。

参数 μ 对 d^{LM} 的影响

$$d^{\text{LM}} = -(\mathbf{J}(\mathbf{x})^T \mathbf{J}(\mathbf{x}) + \mu \mathbf{I})^{-1} \mathbf{J}(\mathbf{x})^T \mathbf{r}(\mathbf{x}).$$



Armi jo步长规则下的L-M方法

对任意的 $\mu > 0$,

$$d^{\text{LM}} = -(\mathbf{J}(x)^T \mathbf{J}(x) + \mu \mathbf{I})^{-1} \mathbf{J}(x)^T \mathbf{r}(x).$$

都是下降方向。对其进行线搜索，即得带线搜索的LM方法。

定理 设Armi jo步长规则下的LM方法产生无穷迭代点列 $\{x_k\}$ 。
若 $\{x_k, \mu_k\}$ 的聚点 (x^*, μ^*) 满足 $((J^*)^T J^* + \mu^* I)$ 正定，
则算法全局收敛，即 $\nabla f(x^*) = \mathbf{0}$.

参数 μ 的选取

对LM方法， μ 取值太小， $d(\mu)$ 靠近Gauss-Newton方向，因 $J(x)$ 的奇异性，算法执行时会出现困难； μ 取值过大， $d(\mu)$ 靠近负梯度方向，算法效率会受影响。

如果非线性最小二乘问题的最优值近似为零，则 $\mu_k = \|r(x_k)\|^2$ 是一个具有自适应性质的选项.